

РОССИЙСКО-АРМЯНСКИЙ УНИВЕРСИТЕТ

ИНСТИТУТ МАТЕМАТИКИ, ФИЗИКИ И ВЫСОКИХ ТЕХНОЛОГИЙ
СПЕЦИАЛЬНОСТЬ: ПРИКЛАДНАЯ МАТЕМАТИКА И ИНФОРМАТИКА
КАФЕДРА СИСТЕМНОГО ПРОГРАММИРОВАНИЯ

КУРСОВАЯ РАБОТА

**ТЕМА: "Разработка интерактивного приложения на R Shiny
для моделирования и сравнения статистических методов анализа клинических данных"**

Выполнил: Адамян Роберт Аркадиевич

Студент 3-го курса ПМИ

Научный руководитель: Беджаниян А.Р.

Заведующий кафедрой: д.т.н., доцент Саргсян С.С.

Ереван, 2026

Введение и актуальность работы

Проблема: В сфере медицины и фармакологии объемы собираемых данных растут с каждым днём. При этом врачи и медицинские аналитики, как правило, не умеют программировать на языках R или Python, чтобы проводить сложный статистический анализ.

Решение: Разрабатываемое приложение решает эту проблему. Оно предоставляет пользователю простой графический интерфейс, который полностью скрывает написанный код. Пользователь просто нажимает кнопки, а программа сама выполняет расчеты.

Главный принцип работы: Приложение построено на базе фреймворка Shiny для языка R. Его логика заключается в автоматическом обновлении: как только пользователь меняет любой параметр на экране, программа мгновенно улавливает это изменение, пересчитывает формулы на сервере и обновляет таблицы и графики на экране.

Архитектура пользовательского интерфейса

Структура экрана: Интерфейс приложения разделен на две основные части для удобства работы аналитика.

Левая часть - Панель управления

Используется для загрузки файлов, выбора исследуемых переменных, настройки группировки пациентов и параметров математических моделей.

Правая часть - Рабочая зона

Содержит вкладки для переключения между просмотром исходных данных, сводной статистикой, графиками и результатами моделирования.

Программная реализация: Элементы управления созданы с помощью функций `fluidPage` (динамическая сетка) и `sidebarLayout`. Разделение на вкладки выполнено через `tabsetPanel` и `tabPanel`.

Стек технологий и используемые библиотеки

Программа написана на языке R с использованием специализированных пакетов для обработки данных и построения интерфейса:

shiny

- базовая библиотека для создания веб-приложения и связи интерфейса с серверной частью.

readxl / haven

- модули для чтения файлов Excel (.xlsx) и SPSS - форматов, наиболее распространённых в медицинских исследованиях.

dplyr

- пакет для быстрой фильтрации, сортировки и группировки больших таблиц.

ggplot2 + plotly

- связка для построения графиков: ggplot2 строит изображение, plotly делает его интерактивным.

DT

- библиотека для вывода интерактивных таблиц с возможностью поиска и сортировки по столбцам.

Модуль загрузки и импорта данных

Clinical Data Analyzer

Upload Data File

Browse...

adae.xlsx

Upload complete

Variables for Summary

☐ Select All

Group By:

None

Dependent Variable (Y):

STUDYID

Predictors (X):

Run Analysis

Settings Management

Save Settings (CSV)

DataSummaryPlotsModel

Show10entriesSearch:

	STUDYID	USUBJID	SUBJID	SITEID	COUNTRY	DOMAIN	RFSTDTC
1	CDISCPILOT01	01-701-1015	1015	701	USA	AE	2014-01-02
2	CDISCPILOT01	01-701-1015	1015	701	USA	AE	2014-01-02
3	CDISCPILOT01	01-701-1015	1015	701	USA	AE	2014-01-02
4	CDISCPILOT01	01-701-1023	1023	701	USA	AE	2012-08-05
5	CDISCPILOT01	01-701-1023	1023	701	USA	AE	2012-08-05
6	CDISCPILOT01	01-701-1023	1023	701	USA	AE	2012-08-05

Что происходит на экране:

Пользователь загружает исходный файл. В данном примере загружен реальный медицинский датасет нежелательных явлений adae.xlsx.

Функционал панели:

В левой панели пользователь сразу видит загруженный файл и статус «Upload complete». Ниже система предлагает выбрать переменные для анализа.

Вывод таблицы:

В правой части (вкладка «Data») мы видим первые строки таблицы с важными медицинскими идентификаторами пациентов.

Контроль ошибок:

Вывод таблицы на экран необходим исследователю, чтобы визуально убедиться, что файл прочитан корректно, столбцы не сместились, а кодировка текста не нарушена.

Модуль автоматического расчёта сводной статистики

Upload Data File

Browse...

adae.xlsx

Upload complete

Variables for Summary

EOSSTT

TRTDURD

AGE

SEX

RACE

☐ Select All

Group By:

TRT01P

Dependent Variable (Y):

TRTDURD

Predictors (X):

TRT01P

AGE

SEX

RACE

Run Analysis

Settings Management

Save Settings (CSV)

Load Settings (CSV)

Browse...

settings_2026-06-02.csv

Upload complete

Data

Summary

Plots

Model

Show

25

entries

Search:

Variable	Level	Group	n	Percentage	Mean	Min	Max
EOSSTT	COMPLETED	Placebo	225	74.75			
EOSSTT	DISCONTINUED	Placebo	76	25.25			
EOSSTT	COMPLETED	Xanomeline High Dose	163	35.82			
EOSSTT	DISCONTINUED	Xanomeline High Dose	292	64.18			
EOSSTT	COMPLETED	Xanomeline Low Dose	136	31.26			
EOSSTT	DISCONTINUED	Xanomeline Low Dose	299	68.74			
TRTDURD		Placebo	301	25.27	163.3	7	210
TRTDURD		Xanomeline High Dose	455	38.2	109.99	2	200
TRTDURD		Xanomeline Low Dose	435	36.52	102.8	2	212
AGE		Placebo	301	25.27	75.34	52	89
AGE		Xanomeline High Dose	455	38.2	72.8	56	88
AGE		Xanomeline Low Dose	435	36.52	76.58	51	88
SEX	F	Placebo	171	56.81			
SEX	M	Placebo	130	43.19			
SEX	F	Xanomeline High Dose	173	38.02			
SEX	M	Xanomeline High Dose	282	61.98			
SEX	F	Xanomeline Low Dose	251	57.7			
SEX	M	Xanomeline Low Dose	184	42.3			

Что происходит на экране:

На вкладке «Summary» программа рассчитывает дескриптивную статистику. Выбрана группировка по фактору TRT01P (плацебо, высокая доза, низкая доза).

Умный анализ типов данных:

Программа сама определяет тип переменной:

- Для качественных признаков (EOSSTT): рассчитывается n и процентная доля в группе.
- Для количественных признаков (AGE, TRTDURD): автоматически считаются Mean, Min и Max для каждой группы.

Сохранение сессии:

Кнопка «Save Settings (CSV)» позволяет скачать файл с текущими настройками.

Модуль визуализации данных

Что происходит на экране:

На вкладке «Plots» программа автоматически строит графики на основе выбранных параметров.

Верхний график (Столбчатая диаграмма):

Показывает распределение завершивших (COMPLETED) и досрочно прекративших (DISCONTINUED) исследование пациентов. В группах с препаратом процент выбывших значительно выше, чем в группе плацебо.

Нижний график (Круговая диаграмма):

Наглядно отображает структуру выборки: 38.2% - высокая доза, 36.5% - низкая доза, 25.3% - плацебо. Распределение участников между группами выглядит достаточно сбалансированным.

Upload complete

Variables for Summary

EOSSTT TRTDURD AGE
SEX RACE

☐ Select All

Group By:
TRT01P

Dependent Variable (Y):
TRTDURD

Predictors (X):
TRT01P AGE SEX RACE

Run Analysis

Settings Management

Save Settings (CSV)


Load Settings (CSV)

Browse... settings_2026-06-06.csv


Upload complete



Pie Chart: TRT01P



Статистическое моделирование. Множественная линейная регрессия



Суть анализа:

На вкладке «Model» оценивается влияние факторов на результат. Зависимая переменная (Y) - TRTDURD. Предикторы (X): группа терапии TRT01P, возраст AGE, пол SEX и раса RACE.

Как получены данные:

При нажатии «Run Analysis» серверная часть запускает функцию `lm()` - метод наименьших квадратов (МНК). Формируется матрица коэффициентов и выводится в удобной таблице.

График под таблицей:

Точечная диаграмма (strip plot) визуализирует разброс длительности лечения по трём группам терапии, помогая заметить аномалии или выбросы в данных.

Математическая модель множественной линейной регрессии

Общий вид модели:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \varepsilon$$

Применение к нашей задаче:

$$\text{TRTDURD} = \beta_0 + \beta_1 \cdot \text{TRT01P} + \beta_2 \cdot \text{AGE} + \beta_3 \cdot \text{SEX} + \beta_4 \cdot \text{RACE} + \varepsilon$$

Y Зависимая переменная

TRTDURD - длительность лечения в днях

β_0 Свободный член (Intercept)

Базовое значение Y при всех X = 0

$\beta_1 \dots \beta_k$ Коэффициенты регрессии

Оцениваемые параметры - влияние каждого предиктора

$X_1 \dots X_k$ Предикторы

TRT01P, AGE, SEX, RACE - переменные

ε Случайная ошибка

$\varepsilon_i \sim N(0, \sigma^2)$ - ненаблюдаемое отклонение

Метод наименьших квадратов и оценка коэффициентов

Цель метода — найти вектор коэффициентов $\hat{\beta}$, минимизирующий сумму квадратов остатков (RSS):

$$RSS = \sum_i (y_i - \hat{y}_i)^2 = \sum_i (y_i - \beta_0 - \beta_1 x_{i1} - \dots - \beta_k x_{ik})^2 \rightarrow \min$$

МНК-оценка вектора коэффициентов:

$$\hat{\beta} = (X^T X)^{-1} \cdot X^T y$$

Свойства МНК-оценок (теорема Гаусса–Маркова):

Несмещённость

$$E[\hat{\beta}] = \beta$$

Ожидаемое значение оценки совпадает с истинным значением параметра.

Эффективность

Минимальная дисперсия

МНК-оценки имеют наименьшую дисперсию среди всех линейных несмещённых оценок.

Состоятельность

$$\hat{\beta} \rightarrow \beta \text{ при } n \rightarrow \infty$$

С ростом объёма выборки оценка сходится к истинному значению параметра.

Статистические гипотезы, t-тесты и p-value

Для каждого предиктора X_j проверяется пара статистических гипотез:

H_0 (нулевая гипотеза)

$$\beta_j = 0 \text{ - фактор } X_j \text{ не влияет на } Y$$

Влияние фактора отсутствует

H_1 (альтернативная гипотеза)

$$\beta_j \neq 0 \text{ - фактор } X_j \text{ значимо влияет на } Y$$

Влияние фактора существует

t-статистика Стьюдента:

$$t = \hat{\beta}_j / SE(\hat{\beta}_j) \sim t(n - k - 1)$$

Распределение при верной H_0 :
статистика Стьюдента с $(n - k - 1)$
степенями свободы

p-value и правило принятия решения:

$$p\text{-value} = P(|T| > |t_{\text{набл}}| \mid H_0)$$

$p < \alpha$ ($\alpha = 0.05$) $\rightarrow H_0$ отвергается

Влияние фактора статистически значимо на выбранном уровне значимости

$p \geq \alpha$ ($\alpha = 0.05$) $\rightarrow H_0$ не отвергается

Нет оснований утверждать о значимом влиянии фактора

Подробный математический разбор результатов моделирования

На скриншоте с результатами моделирования мы получили итоговую статистическую таблицу. Объясним математический смысл каждого столбца:

Estimate

(Оценка коэф.)

Показывает силу и направление влияния фактора.

- TRT01PXanomeline High Dose: коэффициент -54.29 - при приёме высокой дозы длительность лечения в среднем сокращается на 54 дня по сравнению с плацебо.

Std. Error

(Стд. ошибка)

Показывает погрешность расчёта коэффициента. Чем она меньше, тем точнее модель нашла зависимость. Для групп препарата ошибка очень мала (всего 4.6), что говорит о высокой точности.

t value

(t-статистика)

Отношение коэффициента к его ошибке ($t = \text{Estimate} / \text{Std. Error}$). Показывает, во сколько раз значение коэффициента превышает случайную погрешность. Значения -11.7 и -12.9 - очень высокие показатели.

Pr(>|t|)

(p-значение)

Самый важный показатель. Это вероятность наблюдаемого или более крайнего значения t-статистики при условии верности H_0 . Если $p\text{-value} < 0.05$, влияние фактора статистически значимо на выбранном уровне значимости.

Анализ и интерпретация числовых результатов

Разберём конкретные значения p -value из таблицы нашего приложения, чтобы сделать научно обоснованные выводы:

ЗНАЧИМ Влияние препарата (Xanomeline High и Low)	$\text{Pr}(> t) = 0$	В столбце $\text{Pr}(> t)$ указан 0 (очень маленькое число, округлившееся до нуля). Так как $0 < 0.05$, имеются статистически значимые свидетельства наличия связи между группой терапии и длительностью лечения. Это может быть связано с побочными эффектами, из-за которых пациенты прекращали лечение.
НЕ ЗНАЧИМ Влияние возраста (AGE)	$p = 0.8944$	Значение $p = 0.8944 \gg 0.05$. Статистически значимого влияния возраста пациента на длительность лечения обнаружено не было.
НЕ ЗНАЧИМ Влияние пола (SEX/M)	$p = 0.3062$	Значение $p = 0.3062 > 0.05$. Статистически значимого влияния пола пациента на длительность лечения обнаружено не было.
НЕ ЗНАЧИМ Влияние расы (RACE)	$p = 0.77\text{--}0.84$	Значения p лежат в диапазоне 0.77–0.84. Статистически значимого влияния расовой принадлежности на исследуемый показатель обнаружено не было.

Заключение и результаты работы

Итог разработки: Создано полноценное программное приложение «Clinical Data Analyzer» на языке R с использованием технологий Shiny, предоставляющее готовый инструмент для биостатистического анализа.

Достигнутые результаты:

- 1 Реализован гибкий модуль загрузки медицинских данных из файлов Excel.
- 2 Автоматизирован процесс расчёта описательных статистик с разделением на качественные и количественные признаки.
- 3 Разработан визуальный блок с интерактивными графиками.
- 4 Интегрирован модуль построения моделей линейной и логистической регрессии.

Практическая ценность: Программа позволяет проводить полноценные исследования и проверять медицинские гипотезы без написания кода, что снижает вероятность ошибок при выполнении рутинных аналитических процедур.

Перспективы развития приложения

01 Расширение набора статистических моделей

- Логистическая регрессия - для анализа бинарных исходов: завершил пациент исследование или прервал лечение досрочно
- ANOVA и ANCOVA - для одновременного сравнения средних значений показателей между тремя и более группами терапии

02 Модели выживаемости

- Kaplan-Meier - построение кривой выживаемости: показывает, какая доля пациентов остаётся в исследовании через 30, 60, 90 и более дней
- Соx-регрессия - оценка влияния нескольких факторов одновременно на время до наступления события (выбывание, выздоровление, смерть)

03 Автоматическая генерация отчётов

- Выгрузка полных результатов анализа в формате PDF или Word - с таблицами коэффициентов, графиками и текстовыми выводами одним нажатием кнопки
- Стандартизированные шаблоны отчётности в соответствии с требованиями CDISC / ICH E9, принятыми в фармацевтической отрасли

04 Расширение источников данных и развёртывание

- Поддержка REDCap API и форматов JSON/XML - для подключения к системам сбора клинических данных в реальном времени без ручной выгрузки файлов
- Публикация приложения на платформе shinyapps.io - для удалённого доступа через браузер без необходимости устанавливать R на компьютер